

Anno Accademico 2025/2026

Leonardo Donati

Appunti

Materia

Teoria e esercizi.



UNIMORE
UNIVERSITÀ DEGLI STUDI DI
MODENA E REGGIO EMILIA

Indice

1	Introduzione	3
1.1	Ripasso Algebra Lineare	3
1.2	Ripasso Statistica	3
1.3	Machine Learning	4
2	Apprendimento Supervisionato	5
2.1	Dati	5
2.2	Processo di Apprendimento Supervisionato	5
2.3	Apprendimento	6
2.3.1	Misure di valutazione	6
2.3.2	Modello di valutazione	6
2.4	Iperparametri	6
2.5	Altre Misure di Classificazione	7

Capitolo 1

Introduzione

1.1 Ripasso Algebra Lineare

DEFINITION Spazio vettoriale

Lo **spazio vettoriale** $\mathbb{R}^n$ è un insieme di elementi $x = [x_1, \dots, x_n]$ where each $x_i \in \mathbb{R}$. Gli elementi x sono chiamati **vettori** e soddisfano queste proprietà:

1. **Addizione:** Se $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^n$, allora $x + y = [x_1 + y_1, \dots, x_n + y_n] \in \mathbb{R}^n$.
2. **Prodotto scalare:** Se $x \in \mathbb{R}^n$ e $a \in \mathbb{R}$ allora, $a \cdot x = [a \cdot x_1, \dots, a \cdot x_n]$.
3. **Prodotto interno:** Se $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^n$ allora, $x \cdot y = \sum_{i=1}^n x_i \cdot y_i$.

DEFINITION Matrice

Una **matrice** $X \in \mathbb{R}^{n \times m}$ è un vettore rettangolare di elementi $x_{ij} \in \mathbb{R}$, $1 \leq i \leq n$, $1 \leq j \leq m$:

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} \end{pmatrix}$$

Deve supportare queste operazioni:

1. **Addizione:** Se $X \in \mathbb{R}^{n \times m}$, $Y \in \mathbb{R}^{n \times m}$ e $Z = X + Y$, allora $Z \in \mathbb{R}^{n \times m}$ e $Z_{ij} = X_{ij} + Y_{ij}$.
2. **Prodotto scalare:** Se $X \in \mathbb{R}^{n \times m}$, $a \in \mathbb{R}$ e $Z = a \cdot X$, allora $Z \in \mathbb{R}^{n \times m}$ e $Z_{ij} = a \cdot X_{ij}$.
3. **Prodotto fra matrici:** Se $X \in \mathbb{R}^{n \times m}$, $Y \in \mathbb{R}^{m \times n}$ e $Z = X \cdot Y$, allora $Z \in \mathbb{R}^{n \times n}$ e $Z_{ij} = \sum_{k=1}^m X_{ik} \cdot Y_{kj}$.

1.2 Ripasso Statistica

DEFINITION Distribuzione di Probabilità

Una distribuzione di probabilità P su uno spazio campionario Ω è un'applicazione dai sottoinsiemi di Ω ai numeri reali che soddisfa le seguenti condizioni:

- **Non-negatività:** $P(\alpha) \geq 0$, $\forall \alpha \subseteq \Omega$.
- **Normalizzazione:** $P(\Omega) = 1$.
- **Additività:** $\forall \alpha, \beta \subseteq \mathbb{R}$ che sono insiemi disgiunti, $P(\alpha \cup \beta) = P(\alpha) + P(\beta)$.

1.3 Machine Learning

DEFINITION Machine Learning

Il **machine learning** è un campo di studio che conferisce ai computer la capacità di apprendere senza essere esplicitamente programmati.

Esistono due tipi di approcci:

1. **Non parametrico:** l'apprendimento avviene memorizzando i dati di addestramento (memorizzazione).
2. **Parametrico:** l'apprendimento avviene utilizzando un algoritmo per adattare i parametri di un modello matematico o statistico sulla base di dati di addestramento. Per esempio:

$$f_{\theta}(x) = \sum_{d=1}^D \theta_d x_d$$

Capitolo 2

Apprendimento Supervisionato

2.1 Dati

Un insieme di record di dati $X \in X^k$, chiamati anche **esempi**, **istanze** o **casi** sono descritti da:

- k attributi (**Features**): $x = x_1, x_2, \dots, x_k$.
- Una **classe**: ogni esempio è etichettato con una classe target predefinita $c \in C$.

L'obiettivo è imparare un modello di classificazione dai dati che possono essere usati per predire la classe di nuovi casi.

2.2 Processo di Apprendimento Supervisionato

Il processo è diviso in due step:

1. Imparare un modello usando idati dell'allenamento.
2. Testare il modello con dati mai usati per vederne l'**accuratezza**.

$$\text{Accuratezza} = \frac{\text{Numero di classificazioni corrette}}{\text{Numero totali di casi}}$$




Figura 2.1: Training pipeline.




Figura 2.2: Inference pipeline.

2.3 Apprendimento

DEFINITION Apprendimento

Dati un dataset D , una classe compito C e una funzione di prestazione L , si dice che un sistema informatico apprende il compito C dai dati D se, dopo aver osservato D , la prestazione misurata tramite L migliora fino a raggiungere un livello superiore a quello di una scelta casuale.

In altre parole, i dati aiutano il sistema a migliorare le proprie prestazioni rispetto all'assenza di apprendimento.

ASSUNZIONE FONDAMENTALE I.I.D

L'apprendimento è possibile solo se il training e l'inferenza sono fatti usando dati dalla stessa distribuzione $x \sim P(X)$. Detto questo, i campioni usati sono indipendenti e identicamente distribuiti (i.i.d), dal training all'inferenza.

2.3.1 Misure di valutazione

Oltre all'accuratezza, che abbiamo visto in precedenza, ci sono molti altri metodi per valutare:

- **Efficienza:**
 - Tempo usato per costruire il modello.
 - Tempo per usare il modello.
- **Robustezza:** gestire il rumore e valori mancanti.
- **Scalibilità:** efficienza in database basati su dischi.
- **Interpretabilità:** comprensibilità e approfondimenti forniti dal modello.
- **Compattezza del modello:** dimensione dell'albero o numero di regole.

2.3.2 Modello di valutazione

Un modello usato è l'**Holdout Set**, dove il dataset D a disposizione viene diviso in due insiemi disgiunti:

- **Insieme per il training**, T_r .
- **Insieme per l'inferenza**, T_e .

NOTA BENE

L'insieme di addestramento non deve essere utilizzato per i test e l'insieme di test non deve essere utilizzato per l'apprendimento. Un insieme di test non visto fornisce una stima imparziale dell'accuratezza.

Questo metodo è solitamente usato quando i dataset D sono molto larghi.

2.4 Iperparametri

Tutti i classificatori presentano parametri aggiuntivi, denominati **iperparametri** e non vengono appresi, bensì selezionati in fase di progettazione prima dell'addestramento.

Diverse configurazioni degli iperparametri possono modificare in modo significativo le prestazioni del modello. Viene usata un'ulteriore suddivisione del dataset D , utilizzata per la messa a punto degli iperparametri e per la selezione del modello migliore, chiamato **insieme di validazione**.

EXAMPLE Train-Validation-Test

- Dato un dataset D , partizioniamo randomicamente i dati in un insieme di allenamento T_r , uno per la validazione V e uno per il test T_e . Di solito con 60/20/20, 80/10/10 o simile.
- I modelli M_i imparano su T_r per ogni scelta dell'iperparametro H_i .
- L'errore di validazione Val_i di ogni modello M_i viene valutato sull'insieme V .
- Vengono selezionati gli iperparametri H_* che presentano il valore più basso di Val_i e il classificatore viene riaddestrato utilizzando tali iperparametri sull'insieme $T_r + V$, ottenendo un modello finale M_* .
- La capacità di generalizzazione viene stimata valutando l'errore o l'accuratezza di M_* sui dati dell'insieme di test T_e .

EXAMPLE k-fold Crossvalidation

Il metodo viene spesso utilizzato quando il dataset non è sufficientemente ampio da consentire di ottenere un test set consistente.

- Partizioniamo randomicamente un dataset D in un insieme di K blocchi $B_1, \dots, B_K$.
- Per ogni fold di cross-validation $k = 1, \dots, K$:
 - Assegna $T_e = B_k$ e $T_r = D - B_k$ (i rimanenti $K - 1$ blocchi).
 - Impara il modello M_k su T_r e testalo su B_k .
- Il processo produce k accurattezze.
- La stima finale delle prestazioni del modello è la media delle K accurattezze.

2.5 Altre Misure di Classificazione

L'accuratezza non è l'unica misura e in alcuni casi non è nemmeno utilizzabile. Per questo vengono usate anche misure:

- **Precisione:** è il numero di esempi positivi classificati correttamente diviso per il numero totale di esempi classificati come positivi.

$$p = \frac{TP}{TP + FP}$$

- **Recall:** è il numero di esempi positivi correttamente classificati diviso per il numero totale di esempi positivi effettivi nell'insieme di test.

$$r = \frac{TP}{TP + FN}$$

- **F1-score:** è la media armonica di precisione e recall. Dà maggior peso al valore più basso.

$$\frac{1}{F1} = \frac{1}{p} + \frac{1}{r}$$

DEFINITION Cross-Entropy

L'entropia incrociata è una misura della teoria dell'informazione relativa alla codifica dei messaggi utilizzando il numero di bit. Valuta il numero medio di bit per scoprire un dato codificato da una distribuzione Q mentre quello originale era P .

$$\mathbb{E}_P[l_i] = \sum_x P(x) \log_2 \frac{1}{Q(x)} = - \sum_x P(x) \log_2 Q(x)$$